# Тестирование программного обеспечения

# МКН СПбГУ, осень 2024

Федор Мамаев, 22Б09

# Отчёт о выполнении Д/3

**Что требовалось:** написать фаззер для тестирования метода org.jsoup.Jsoup.parse(java.lang.String) из библиотеки <u>Jsoup</u>, который преобразует строку в HTML-документ, и найти в нём ошибки (выбросы исключений).

Ссылка на pull-request в репозитории с выполненным Д/3: <a href="https://github.com/FedMam/Joker2023-Verification-fall-2024-FedMam/pull/1">https://github.com/FedMam/Joker2023-Verification-fall-2024-FedMam/pull/1</a>

#### Как устроен код в репозитории:

Все мои наработки находятся в пакете me.markoutte.joker.hwl. Внутри пакета находятся 5 пакетов, соответствующих 5 шагам: stepl, step2 и т. д., так же, как и в пакете me.markoutte.joker.parse, который уже был в репозитории (там 3 шага). Также внутри находится пакет strategies, в котором реализованы различные стратегии фаззинга и мутации. Ошибки в методе найти не удалось (возможно, их вообще нет), но попробовано много разных методов фаззинга. Краткое описание 5 шагов:

- **Шат 1**: почти точная копия шага 1 из пакета me.markoutte.joker.parse, отличается тем, что может использовать различные стратегии фаззинга (про них подробнее см. ниже). Генерирует случайные сэмплы и подаёт их на вход методу, пока не закончится отведённое время.
- **Шаг 2**: копия шага 2 из пакета parse. Генерирует случайные сэмплы, а потом пытается их случайно менять (мутировать). Отличается тем, что может использовать разные стратегии фаззинга и мутации.
- **Шаг 3**: копия шага 3 из пакета parse. При помощи инструментации может составлять ID для сэмпла на основе того, какие строчки кода были посещены при запуске метода с этим сэмплом на входе. При помощи мутации пытается пройти по как можно большему числу различных путей в коде метода.
- Шат 4 (на самом деле был выполнен позже шага 5): При помощи инструментации может определить точный набор строчек кода, которые были посещены при запуске метода. Генерирует случайные сэмплы и считает максимальное покрытие (максимальное количество посещённых строчек кода), достигнутое каким-то сэмплом. Можно включить или отключить мутацию. Создан для тестирования разных стратегий фаззинга и мутации и определения, какая из них лучше.
- **Шаг** 5: При помощи инструментации определяет покрытие, так же, как и на предыдущем шаге. На этом шаге реализован генетический алгоритм, который генерирует случайные сэмплы, пытаясь достичь максимального покрытия. Алгоритм действительно обучается (то есть, достигнутое покрытие увеличивается с течением времени), но работает очень медленно, и для достижения значимых результатов он должен работать долгое время.

## Стратегии фаззинга, которые были реализованы

Для каждой стратегии приведен средний по 5 запускам результат выполнения шага 4 без мутации (максимальное покрытие случайного сэмпла) со случайным сидом в течение 25 секунд и результат работы шага 5 в течение 10 минут с сидом 192837 (используются все стратегии мутации одновременно, т. е. на каждом шагу выбирается случайная).

Класс	Описание	Пример (фрагмент)	IIIar 4	IIIar 5
GarbageStrategy	Генерация случайной последовательности байт	¶4SP└чt≤р╗;HpT fюoK░'d©©Ed÷‡^√╥≥	1060.8	1320
ValidCharsStrategy	Генерация случайной последовательности допустимых в HTML символов	lfAnVbAY5>DFGWfa-"z;0UE&p6_ZtJvZ p-16Q8xEeC-E;mIjeN-WBe1ZPKQP- H=-Hqt1S;wU_EE-AGrhn0Pn17C!X19H	1214.6	1445
SpecialCharsStrategy	Генерация случайной последовательности специальных символов HTML	!>!-/>/<>= -!</;=-</< -;//>/ >>/>-<-<<<>=/>>/> -; // >;&>;/>=;>/!<& ! >/<>>/; <</td <td>1186.4</td> <td>900</td>	1186.4	900
HTMLTagsStrategy	Генерация НТМL-тегов с названиями из случайных байт	ҕ҄¯ъѩЯ ь <иТҕ҄ӀдМљ> <br ЅЏхт^9> Ц҃ヹ。? ™*т > Ъјѕ>џ> ВҔ҅Ŷ <>	1281.0	1367
HTMLTagsValidStrategy	Генерация HTML-тегов с допустимыми в HTML названиями в правильной последовательности (т. е. есть открывающие и закрывающие теги и они правильным образом включают в себя другие теги)	<pre><g><plhigitgb><acza></acza> <tshaqt></tshaqt><latzebhar> </latzebhar></plhigitgb> <vhjucij></vhjucij></g></pre>	1166.8	1045
HTMLTagsAttributesStr ategy	Генерация НТМL-тегов в правильной последовательности с атрибутами	<pre><nsm wihiwwjv=", ¹ÑôZX)?ÂJ" xvgyowkbet="Riw@_Û\fN[¿+LVí- 2Eb.âifIkFEHlzÛyFÊFÉIt^A—#ā-ā'h" î"=""><wvlnd mica="J4L&lt;;G·Đ'Œ\)2,Û} B±Îw榰º}ÇnéQÛ\dÕÜ,"><!-- wvlnd--><viguspdu></viguspdu><!-- nsm--><vhbhjltqfv 'ö{ˇpeéá"="" czcmghf="K%" m*ê¿s'p@x="" nzykglmqp="ä-Y  à™.ÕÜI" oreltlttc="Ā[~,ÎGq0/XS\f" ý<="">IRæKÞ†ð—ðþhNÖµE É+KÔê"&gt;</vhbhjltqfv></wvlnd></nsm></pre>	1505.6	1352
CorruptedHTMLStrategy	Алгоритм берёт немного изменённый исходный код страницы <a href="https://acm.math.spbu.ru/">https://acm.math.spbu.ru/</a> и случайным образом изменяет в нём несколько символов	<pre><!DOCTYPE html>    ?<html></html></pre>	1900.2	1821
GrammarBasedFuzzing	Grammar-based fuzzing с грамматикой, описанной ниже	<pre><aac js="XXYOh" l="guc" s="" y=";b">j?A<!--g;coJ--><caa krj="guw;Bi" o="B"><cca><up><!-- cca--><h><exxw y="gGQKf"><s><y wrh="ReeNQVM"><!--daOdD -->&amp;fDIDaXRdr!&amp;k</y></s></exxw></h></up></cca></caa></aac></pre>	1461.4	1610

В Grammar-based Fuzzing использовалась следующая грамматика:

```
\{буква\} = a \mid b \mid c \mid ... \mid z
\{Cимвол\} = a \mid b \mid ... \mid z \mid A \mid B \mid ... \mid Z \mid 0 \mid 1 \mid ... \mid 9
                     | . | , | : | ; | - | ! | ? | ( | )
\{\mathsf{им}\mathsf{Я}\} = \{\mathsf{б}\mathsf{У}\mathsf{K}\mathsf{B}\mathsf{A}\} | \{\mathsf{б}\mathsf{Y}\mathsf{K}\mathsf{B}\mathsf{A}\} \{\mathsf{и}\mathsf{M}\mathsf{Я}\}
\{\text{текст}\} = \varepsilon \mid \{\text{символ}\}\{\text{текст}\}
{спецсимвол} = &{umя};
\{aтрибут\} = \{ums\} = \{tekct\} "
\{aтрибуты\} = \varepsilon \mid \{aтрибут\}\{aтрибуты\}
\{тег\} = <\{имя\}\{атрибуты\}>
{закрытый тег} = <{имя}{атрибуты}/>
{комментарий} = <!--{текст}-->
\{\text{контент}\} = \varepsilon \mid \{\text{текст}\}\{\text{контент}\} \mid \{\text{спецсимвол}\}\{\text{контент}\} \mid \{\text{тег}\}\{\text{контент}\}
                      | {закрытый тег}{контент} | {комментарий}{контент}
                      | {пара тегов}{контент}
\{\text{пара тегов}\} = \langle s \{\text{атрибуты}\} \rangle \{\text{контент}\} \langle s \rangle для всех строк s из ограниченного набора строк
(т. к. по сути, для бесконечного набора строк s такое не описывается грамматикой). Набор:
\{x_1x_2x_3 для x_i \in \{a,b,c\}\} \cup \{html,head,body,div,script\}
```

Из этой таблицы мы можем сделать следующие выводы. Во-первых, разные стратегии генерации входных данных дают разное покрытие тестируемого кода, что ожидаемо. Во-вторых, генетический алгоритм не всегда показывает лучший результат, чем просто случайная генерация. По-видимому, это связано либо с тем, что сложные стратегии занимают много времени для генерации данных и алгоритм не успевает за 10 минут сделать достаточно итераций, либо с тем, что такие стратегии дают ему меньше свободы.

### Стратегии мутации, которые были реализованы

Начальный нетерминальный символ: {пара тегов}

В таблице приведён результат выполнения шага 5 со стратегией фаззинга GarbageStrategy и каждой стратегией мутации в течение 10 минут с сидом 192846. Указан результат лучшего сэмпла в конце обучения (при первой случайной генерации лучший сэмпл имеет результат 1208). Все стратегии описаны в классе strategies. MutationStrategies.

Название функции	Описание	Результат работы
brush	Генерирует случайные числа from и until и заполняет случайный отрезок байтового массива значениями от from до until	1330
shotgun	Генерирует числа from и until и меняет значения не более $\sqrt{n}$ случайных байт на значения от from до until, где $n$ - длина байтового массива	1243
spray	То же самое, но может поменять до $n$ байт	1347
eraser	Заполняет случайный отрезок длины не более $\sqrt{n}$ нулями	1061
solidBrush	Заполняет случайный отрезок длины до $n$ одинаковыми значениями	1302
iotaBrush	Заполняет случайный отрезок длины до $n$ арифметической прогрессией с разностью $1$	1265
incBrush	Прибавляет 1 к байтам на случайном отрезке длины до $n$	721
plusBrush	Генерирует случайное значение и прибавляет его к байтам отрезка длины до $n$	1283
random	Каждый раз выбирается случайная стратегия из вышеперечисленных	1260